Контрольная работа №1

Робертс Даниил Александрович

Москва 2022

1 Рубежный контроль №1

1.1 Технологии разведочного анализа и обработки данных.

Задача: Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

Датасет: https://www.kaggle.com/noriuk/us-education-datasets-unification-project

```
[9]: import pandas as pd
import seaborn as sns
from sklearn.impute import SimpleImputer
```

1.2 Общая информация о данных

```
data = pd.read_csv('states_all.csv', sep=',')
      data.head()
[11]:
                                               ENROLL
[11]:
              PRIMARY_KEY
                                 STATE
                                        YEAR
                                                        TOTAL_REVENUE
                                                                        FEDERAL_REVENUE
             1992_ALABAMA
      0
                               ALABAMA
                                        1992
                                                   NaN
                                                            2678885.0
                                                                                304177.0
      1
              1992_ALASKA
                                ALASKA
                                        1992
                                                   NaN
                                                            1049591.0
                                                                                106780.0
      2
             1992_ARIZONA
                               ARIZONA
                                         1992
                                                   NaN
                                                            3258079.0
                                                                                297888.0
      3
            1992_ARKANSAS
                              ARKANSAS
                                         1992
                                                   NaN
                                                            1711959.0
                                                                                178571.0
         1992_CALIFORNIA
                           CALIFORNIA
                                         1992
                                                           26260025.0
                                                                               2072470.0
                                                   NaN
         STATE_REVENUE
                         LOCAL_REVENUE
                                          TOTAL_EXPENDITURE
                                                              INSTRUCTION_EXPENDITURE
      0
              1659028.0
                               715680.0
                                                   2653798.0
                                                                              1481703.0
      1
               720711.0
                               222100.0
                                                    972488.0
                                                                               498362.0
      2
              1369815.0
                              1590376.0
                                                   3401580.0
                                                                              1435908.0
      3
               958785.0
                               574603.0
                                                   1743022.0
                                                                               964323.0
      4
             16546514.0
                              7641041.0
                                                  27138832.0
                                                                             14358922.0
               GRADES_4_G
                            GRADES_8_G
                                         GRADES_12_G
                                                       GRADES_1_8_G
                                                                      GRADES_9_12_G
                  57948.0
                               58025.0
                                             41167.0
      0
                                                                 NaN
                                                                                 NaN
      1
                   9748.0
                                8789.0
                                              6714.0
                                                                 {\tt NaN}
                                                                                 NaN
         . . .
                  55433.0
                               49081.0
                                             37410.0
                                                                 NaN
                                                                                 NaN
```

```
4
                             363296.0
                                           270675.0
                                                               NaN
                                                                               NaN
                 418418.0
         GRADES_ALL_G
                        AVG_MATH_4_SCORE
                                           AVG_MATH_8_SCORE
                                                              AVG_READING_4_SCORE
      0
             731634.0
                                    208.0
                                                       252.0
                                                                             207.0
      1
              122487.0
                                      NaN
                                                         NaN
                                                                               NaN
      2
                                    215.0
                                                       265.0
                                                                             209.0
             673477.0
      3
             441490.0
                                    210.0
                                                       256.0
                                                                             211.0
      4
                                    208.0
                                                       261.0
                                                                             202.0
            5254844.0
         AVG_READING_8_SCORE
      0
                          NaN
      1
                          NaN
      2
                          NaN
      3
                          NaN
      4
                          NaN
      [5 rows x 25 columns]
[12]: data.describe()
[12]:
                     YEAR
                                  ENROLL
                                          TOTAL_REVENUE
                                                          FEDERAL_REVENUE
             1715.000000
                           1.224000e+03
                                                             1.275000e+03
                                           1.275000e+03
      count
              2002.075219
                           9.175416e+05
                                           9.102045e+06
                                                             7.677799e+05
      mean
      std
                 9.568621
                           1.066514e+06
                                           1.175962e+07
                                                             1.146992e+06
              1986.000000
                           4.386600e+04
                                           4.656500e+05
                                                             3.102000e+04
      min
      25%
              1994.000000
                           2.645145e+05
                                           2.189504e+06
                                                             1.899575e+05
      50%
             2002.000000
                           6.499335e+05
                                           5.085826e+06
                                                             4.035480e+05
      75%
                           1.010532e+06
                                                             8.279320e+05
             2010.000000
                                           1.084516e+07
      max
              2019.000000
                           6.307022e+06
                                           8.921726e+07
                                                             9.990221e+06
             STATE_REVENUE
                            LOCAL_REVENUE
                                             TOTAL_EXPENDITURE
              1.275000e+03
                              1.275000e+03
                                                   1.275000e+03
      count
              4.223743e+06
                              4.110522e+06
                                                   9.206242e+06
      mean
      std
              5.549735e+06
                              5.489562e+06
                                                   1.199279e+07
              0.00000e+00
                              2.209300e+04
                                                   4.816650e+05
      min
      25%
              1.165776e+06
                              7.151210e+05
                                                   2.170404e+06
      50%
              2.537754e+06
                              2.058996e+06
                                                   5.242672e+06
      75%
              5.055548e+06
                              4.755293e+06
                                                   1.074420e+07
      max
              5.090457e+07
                              3.610526e+07
                                                   8.532013e+07
             INSTRUCTION_EXPENDITURE
                                        SUPPORT_SERVICES_EXPENDITURE
                                                         1.275000e+03
      count
                         1.275000e+03
                                                         2.682587e+06
                         4.768010e+06
      mean
                                                         3.357214e+06
      std
                         6.300569e+06
      min
                         2.655490e+05
                                                         1.399630e+05
      25%
                                                         6.380760e+05
                         1.171336e+06
```

27651.0

NaN

NaN

3

. . .

34632.0

36011.0

```
50%
                         2.658253e+06
                                                         1.525471e+06
      75%
                         5.561959e+06
                                                         3.222924e+06
      max
                         4.396452e+07
                                                         2.605802e+07
             OTHER EXPENDITURE
                                          GRADES_4_G
                                                          GRADES_8_G
                                                                         GRADES_12_G \
                   1.224000e+03
                                         1632.000000
                                                         1632.000000
                                                                         1632.000000
      count
                                  . . .
                                  . . .
                   4.299509e+05
                                        69166.507966
                                                        68106.537377
                                                                        58420.870711
      mean
      std
                   5.347893e+05
                                        79957.990356
                                                        77965.847263
                                                                         67438.530709
      min
                   1.154100e+04
                                         4577.000000
                                                         3371.000000
                                                                         2572.000000
      25%
                   1.034492e+05
                                        18971.500000
                                                        19594.250000
                                                                        16076.500000
                                  . . .
      50%
                   2.717040e+05
                                  . . .
                                        49087.000000
                                                        47880.000000
                                                                        39408.000000
      75%
                   5.172222e+05
                                        78504.250000
                                                        78976.000000
                                                                         69397.250000
      max
                   3.995951e+06
                                       493415.000000
                                                       500143.000000
                                                                       498403.000000
                                  . . .
             GRADES 1 8 G
                            GRADES 9 12 G
                                            GRADES ALL G
                                                           AVG MATH 4 SCORE
      count
             1.020000e+03
                              1.071000e+03
                                            1.632000e+03
                                                                  565.000000
              5.779547e+05
                              2.820691e+05
                                            9.139695e+05
                                                                  236.327434
      mean
      std
             6.757837e+05
                              3.307098e+05
                                            1.055893e+06
                                                                    9.285505
      min
             3.769800e+04
                              1.353000e+04
                                            6.844900e+04
                                                                  192.000000
      25%
                             8.060800e+04
                                            2.480832e+05
              1.649250e+05
                                                                  232.000000
      50%
             4.051115e+05
                             1.869190e+05
                                            6.458050e+05
                                                                  238.000000
             6.439752e+05
                              3.223280e+05
                                             1.043420e+06
      75%
                                                                  242.000000
             3.929869e+06
                              2.013687e+06
                                            6.441557e+06
                                                                  253.000000
      max
                                                       AVG_READING_8_SCORE
              AVG_MATH_8_SCORE
                                AVG_READING_4_SCORE
      count
                    602.000000
                                          650.000000
                                                                 562.000000
                                                                 263.558719
      mean
                    278.280731
                                          218.806154
      std
                     10.343482
                                            7.681805
                                                                   6.612601
      min
                    231.000000
                                          179.000000
                                                                 236.000000
      25%
                    272.000000
                                          215.000000
                                                                 260.000000
      50%
                    280.500000
                                          220.000000
                                                                 265.000000
      75%
                    286.000000
                                          224.000000
                                                                 268.000000
                                          237.000000
      max
                    301.000000
                                                                 280.000000
      [8 rows x 23 columns]
[13]: data.dtypes
[13]: PRIMARY_KEY
                                         object
      STATE
                                         object
      YEAR
                                          int64
                                        float64
      ENROLL
      TOTAL_REVENUE
                                        float64
      FEDERAL_REVENUE
                                        float64
      STATE_REVENUE
                                        float64
```

float64

float64

LOCAL_REVENUE

TOTAL_EXPENDITURE

INSTRUCTION_EXPENDITURE	float64
SUPPORT_SERVICES_EXPENDITURE	float64
OTHER_EXPENDITURE	float64
CAPITAL_OUTLAY_EXPENDITURE	float64
GRADES_PK_G	float64
GRADES_KG_G	float64
GRADES_4_G	float64
GRADES_8_G	float64
GRADES_12_G	float64
GRADES_1_8_G	float64
GRADES_9_12_G	float64
GRADES_ALL_G	float64
AVG_MATH_4_SCORE	float64
AVG_MATH_8_SCORE	float64
AVG_READING_4_SCORE	float64
AVG_READING_8_SCORE	float64
dtype: object	

dtype: object

[14]: data.isnull().sum()

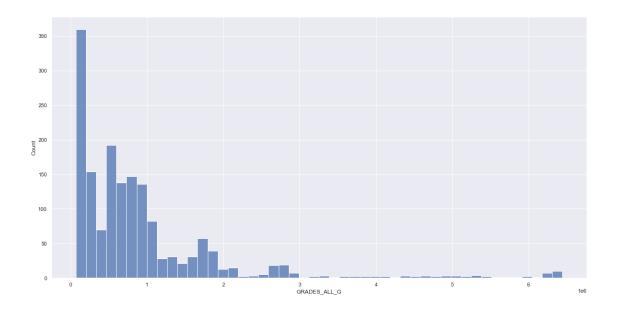
•
0
0
491
440
440
440
440
440
440
440
491
440
173
83
83
83
83
695
644
83
1150
1113
1065
1153

1.3 Заполнение пропусков

Посмотрим процент пропусков для каждой из колонок

```
[15]: total_rows = data.shape[0]
     for col in data.columns:
         null_count = data[data[col].isnull()].shape[0]
         col_type = str(data[col].dtype)
         print(f' {col}, ( {col_type} ) , data loss {null_count / total_rows * 100:.
       \rightarrow 2f}%')
      PRIMARY_KEY, ( object ) , data loss 0.00%
      STATE, (object), data loss 0.00%
      YEAR, (int64), data loss 0.00%
      ENROLL, (float64), data loss 28.63%
      TOTAL_REVENUE, (float64), data loss 25.66%
      FEDERAL_REVENUE, (float64), data loss 25.66%
      STATE_REVENUE, (float64), data loss 25.66%
      LOCAL_REVENUE, (float64), data loss 25.66%
      TOTAL_EXPENDITURE, (float64), data loss 25.66%
      INSTRUCTION_EXPENDITURE, (float64), data loss 25.66%
      SUPPORT_SERVICES_EXPENDITURE, (float64), data loss 25.66%
      OTHER_EXPENDITURE, (float64), data loss 28.63%
      CAPITAL_OUTLAY_EXPENDITURE, (float64), data loss 25.66%
      GRADES_PK_G, (float64), data loss 10.09%
      GRADES_KG_G, ( float64 ) , data loss 4.84%
      GRADES_4_G, (float64), data loss 4.84%
      GRADES_8_G, (float64), data loss 4.84%
      GRADES_12_G, (float64), data loss 4.84%
      GRADES_1_8_G, ( float64 ) , data loss 40.52%
      GRADES_9_12_G, (float64), data loss 37.55%
      GRADES_ALL_G, (float64), data loss 4.84%
      AVG_MATH_4_SCORE, (float64), data loss 67.06%
      AVG_MATH_8_SCORE, (float64), data loss 64.90%
      AVG_READING_4_SCORE, (float64), data loss 62.10%
      AVG_READING_8_SCORE, (float64), data loss 67.23%
[16]: sns.set(rc={"figure.figsize":(20, 10)})
      sns.histplot(data=data['GRADES_ALL_G'])
```

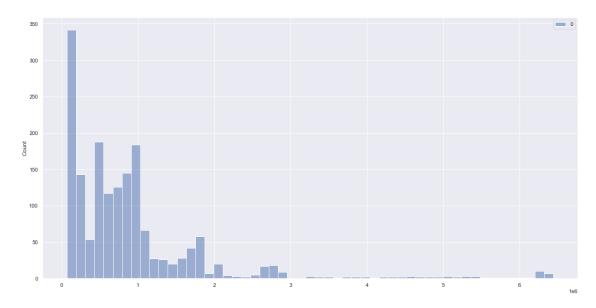
```
[16]: <AxesSubplot:xlabel='GRADES_ALL_G', ylabel='Count'>
```



Заполним ее с применением различных стратегий

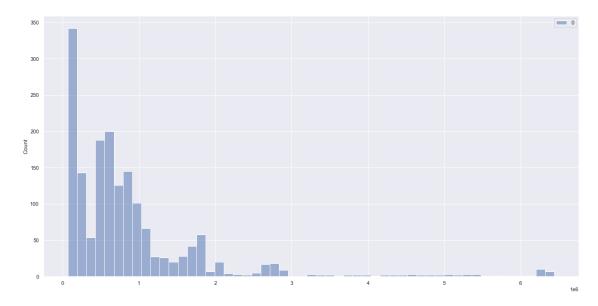
```
[17]: # Заполнение средним
mean_imp = SimpleImputer(strategy='mean')
tot_exp_mean = mean_imp.fit_transform(data[['GRADES_ALL_G']])
sns.histplot(data=tot_exp_mean)
```

[17]: <AxesSubplot:ylabel='Count'>



```
[18]: # Заполнение медианой
median_imp = SimpleImputer(strategy='median')
tot_exp_mean = median_imp.fit_transform(data[['GRADES_ALL_G']])
sns.histplot(data=tot_exp_mean)
```

[18]: <AxesSubplot:ylabel='Count'>



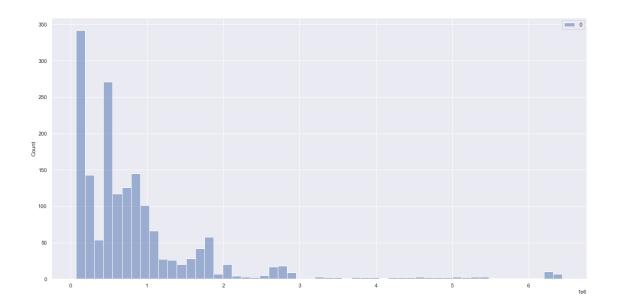
```
[19]: # Заполнение модой

most_freq_imp = SimpleImputer(strategy='most_frequent')

tot_exp_mean = most_freq_imp.fit_transform(data[['GRADES_ALL_G']])

sns.histplot(data=tot_exp_mean)
```

[19]: <AxesSubplot:ylabel='Count'>



Для обработки пропусков был использован класс SimpleImputer и рассмотрены три стратегии, которые он реализует: заполнение средним, медианой и модой. Для колонки GRADES_ALL_G, исходя из гистограмм, лучшего всего подходит заполнение средним, т.к. не так сильно влияет на плотность вероятности распределения.

Для заполнения пропусков в категориальных признаках также используется класс SimpleImputer, только в этом случае он реализует стратегии most frequent (заполнение самым часто встречаемым значением) и constant (заполнение некторой константой).

Для дальнейшего построения модели точно следует исключить признаки AVG_MATH_4_SCORE, AVG_MATH_8_SCORE, AVG_READING_4_SCORE и AVG_READING_8_SCORE, т.к. они имеют слишком много пропусков. Следует оставить колонки GRADES_PK_G, GRADES_KG_G, GRADES_4_G, GRADES_8_G, GRADES_12_G и GRADES_ALL_G т.к. в каждой из них меньше 5 процентов пропусков