Контрольная работа №2

Робертс Даниил Александрович

Москва 2022

1 Рубежный контроль №2

1.1 Методы построения моделей машинного обучения.

Задача: Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Датасет: https://www.kaggle.com/datasets/fivethirtyeight/fivethirtyeight-comic-characters-dataset?select=dc-wikia-data.csv

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.metrics import ConfusionMatrixDisplay, accuracy_score
from sklearn.tree import DecisionTreeClassifier
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import LabelEncoder, OrdinalEncoder
import xgboost as xgb
import graphviz
from sklearn.tree import export_graphviz
from sklearn.model_selection import train_test_split, GridSearchCV,□

→StratifiedKFold
```

```
[8]: data = pd.read_csv('dc-wikia-data.csv', sep=',')
data.head()
```

```
[8]:
        page_id
                                                                            urlslug
                                         name
     0
           1422
                        Batman (Bruce Wayne)
                                                       \/wiki\/Batman_(Bruce_Wayne)
     1
          23387
                        Superman (Clark Kent)
                                                      \/wiki\/Superman_(Clark_Kent)
     2
           1458
                  Green Lantern (Hal Jordan)
                                                \/wiki\/Green_Lantern_(Hal_Jordan)
     3
           1659
                    James Gordon (New Earth)
                                                   \/wiki\/James_Gordon_(New_Earth)
                                               \/wiki\/Richard_Grayson_(New_Earth)
     4
           1576 Richard Grayson (New Earth)
                                    ALIGN
                                                  EYE
                                                              HAIR
        Secret Identity Good Characters
                                            Blue Eyes Black Hair Male Characters
```

```
1 Secret Identity Good Characters
                                          Blue Eyes Black Hair Male Characters
      2 Secret Identity Good Characters Brown Eyes Brown Hair Male Characters
      3 Public Identity Good Characters Brown Eyes White Hair Male Characters
      4 Secret Identity Good Characters
                                           Blue Eyes Black Hair Male Characters
                         ALIVE APPEARANCES FIRST APPEARANCE
        GSM
                                                                YEAR
      O NaN Living Characters
                                     3093.0
                                                   1939, May 1939.0
      1 NaN Living Characters
                                               1986, October 1986.0
                                     2496.0
                                               1959, October 1959.0
      2 NaN Living Characters
                                     1565.0
      3 NaN Living Characters
                                              1987, February 1987.0
                                     1316.0
      4 NaN
            Living Characters
                                                 1940, April 1940.0
                                     1237.0
 [9]: # Удаление ненужных колонок
      data.drop(columns=['page_id', 'name', 'urlslug'], inplace=True)
[10]: data.dtypes
[10]: ID
                          object
      ALIGN
                          object
      EYE
                          object
     HAIR
                          object
      SEX
                          object
      GSM
                          object
      ALIVE
                          object
      APPEARANCES
                         float64
     FIRST APPEARANCE
                          object
     YEAR
                         float64
     dtype: object
     Посмотрим сколько значений пропущено
[11]: total_rows = data.shape[0]
      for col in data.columns:
         null_count = data[data[col].isnull()].shape[0]
         col_type = str(data[col].dtype)
         print(f' {col}, ( {col_type} ) , data loss {null_count / total_rows * 100:.
       \hookrightarrow 2f}%')
      ID, (object), data loss 29.19%
      ALIGN, (object), data loss 8.72%
      EYE, (object), data loss 52.61%
      HAIR, (object), data loss 32.98%
      SEX, (object), data loss 1.81%
      GSM, (object), data loss 99.07%
      ALIVE, (object), data loss 0.04%
      APPEARANCES, (float64), data loss 5.15%
      FIRST APPEARANCE, (object), data loss 1.00%
      YEAR, (float64), data loss 1.00%
```

Удалим столбцы EYE и GSM из-за большого количества пропусков

```
[12]: data.drop(columns=['EYE', 'GSM', 'YEAR'], inplace=True)
```

Удалим строки, содержащие пропуски в столбцах YEAR, FIRST APPEARANCE и ALIGN

```
[13]: data.dropna(axis=0, how='any', subset=['FIRST APPEARANCE', 'ALIGN', \
\[ \rightarrow 'APPEARANCES'], inplace=True)
```

Заполним пропуски в категориальных столбцах при помощих самых часто встречаемых значений

```
[14]: cat_simp_imp = SimpleImputer(strategy='most_frequent')
cat_data_imputed = cat_simp_imp.fit_transform(data.drop(columns=['APPEARANCES']))
data[data.drop(columns=['APPEARANCES']).columns] = cat_data_imputed
data.isnull().sum()
```

```
[14]: ID 0
ALIGN 0
HAIR 0
SEX 0
ALIVE 0
APPEARANCES 0
FIRST APPEARANCE 0
dtype: int64
```

Теперь закодируем категориальные признаки

```
c:\Users\danib\Documents\pyton\myvenv\lib\site-
packages\sklearn\preprocessing\_label.py:115: DataConversionWarning: A column-
vector y was passed when a 1d array was expected. Please change the shape of y
to (n_samples, ), for example using ravel().
    y = column_or_1d(y, warn=True)
```


1.2 Разделение выборки на обучающую и тестовую


В качестве уелевого признака возьмем столбец ALIGN

```
[16]: data_X = data.drop(columns=['ALIGN'])
data_y = data[['ALIGN']]
train_X, test_X, train_y, test_y = train_test_split(data_X, data_y)
```

```
1.3 Дерево решений
[17]: tree_params_search = {
          'max_depth': [2, 4, 6, 8, 10],
          'min_samples_leaf': [0.04, 0.06, 0.08, 0.1],
          'max_features': [0.2, 0.4, 0.6, 0.8, 1]
      }
[18]: grid_search_tree = GridSearchCV(DecisionTreeClassifier(), tree_params_search,_
      ⇒scoring='accuracy', cv=StratifiedKFold(n_splits=5), n_jobs=4)
      grid_search_tree.fit(train_X, train_y)
      grid_search_tree.best_params_, grid_search_tree.best_score_
     c:\Users\danib\Documents\pyton\myvenv\lib\site-
     packages\sklearn\model_selection\_split.py:676: UserWarning: The least populated
     class in y has only 2 members, which is less than n_splits=5.
       warnings.warn(
[18]: ({'max_depth': 4, 'max_features': 0.8, 'min_samples_leaf': 0.1},
      0.5905005117603543)
[19]: tree: DecisionTreeClassifier = grid_search_tree.best_estimator_
      tree.fit(train_X, train_y)
      tree_pred = tree.predict(test_X)
      fig, ax = plt.subplots(figsize=(10, 10))
      ConfusionMatrixDisplay.from_predictions(test_y, tree_pred, ax=ax,__
      →display_labels=le.classes_)
      accuracy_score(tree_pred, test_y)
```

[19]: 0.5854152599594868






1.4 Градиентный бустинг

```
[22]: xgb_model = xgb.XGBClassifier()
     xgb_params = {'learning_rate': [0.01, 0.05, 0.1, 0.12, 0.15, 0.2, 0.3, 0.5, 0.7],
                   'max_depth': [5, 6, 7, 8],
                   'min_child_weight': [2, 3, 5, 11],
                   'n_estimators': [1, 2, 5, 10, 12, 15, 20]}
     xgb_search = GridSearchCV(estimator=xgb_model, param_grid=xgb_params, cv=5,...
      xgb_search.fit(train_X, train_y)
     xgb_search.best_params_, xgb_search.best_score_
     c:\Users\danib\Documents\pyton\myvenv\lib\site-
     packages\sklearn\model_selection\_split.py:676: UserWarning: The least populated
     class in y has only 2 members, which is less than n_splits=5.
       warnings.warn(
[22]: ({'learning_rate': 0.5,
        'max_depth': 5,
        'min_child_weight': 2,
        'n_estimators': 20},
```

0.619091448028456)

[23]: 0.62457798784605



Градиентный бустинг получился точнее, чем дерево решений, но при этом все равно ошибается при определении классов Neutral Characters и Reformed Criminals